

1- Resultados e contas:

- **Número de itemsets:**
 - **Itemset 1** → 3 itemsets (café; pão; manteiga);
 - **Itemset 2** → 3 itemsets (pão e manteiga; pão e café; café e manteiga);
 - **Itemset 3** → 1 itemset (pão e manteiga e café);
- **Número de regras:** 7 regras geradas

Q1 - sup. mínimo aceitável → 0,3
confiança mínima aceitável → 0,8

▷ suporte (Itemset de 1 item):

X leite = $2/10 = 0,2$ ✓ pão = $5/10 = 0,5$ X suco = $2/10 = 0,2$
 ✓ café = $3/10 = 0,3$ ✓ manteiga = $5/10 = 0,5$ (os circuleados possuem o suporte mínimo aceitável)
 X cereja = $2/10 = 0,2$ X amora = $2/10 = 0,2$

▷ suporte (Itemset de 2 itens):

✓ pão e manteiga = $4/10 = 0,4$
 ✓ pão e café = $3/10 = 0,3$
 ✓ café e manteiga = $3/10 = 0,3$

▷ suporte (Itemset de 3 itens):

✓ pão, manteiga e café = $3/10 = 0,3$

▷ confiança (pelas regras de associação geradas - Itemset 2):

✓ pão → manteiga = $\frac{0,4}{0,5} = 0,8$
 ✓ manteiga → pão = $\frac{0,4}{0,5} = 0,8$
 X pão → café = $\frac{0,3}{0,5} = 0,6$
 ✓ café → pão = $\frac{0,3}{0,3} = 1$
 X manteiga → café = $\frac{0,3}{0,5} = 0,6$

▷ confiança (Itemset 3):

✓ café e pão → manteiga = $\frac{0,3}{0,3} = 1$
 ✓ café e manteiga → pão = $\frac{0,3}{0,3} = 1$
 X pão e manteiga → café = $\frac{0,3}{0,4} = 0,75$
 X café → pão e manteiga = $\frac{0,3}{0,5} = 0,6$
 X pão → café e manteiga = $\frac{0,3}{0,5} = 0,6$

▷ Resultados:

• nº de itemsets:
 (1) 3 itemsets (café, pão, manteiga)
 (2) 3 itemsets (pão e manteiga, pão e café, café e manteiga)
 (3) 1 itemset (pão, manteiga e café)

• nº de regras: 7 regras geradas

2- Código implementado: (e devidamente alterado para o dataset de paoemanteiga):

<https://colab.research.google.com/drive/1G0dC7lcdRanyBy5SwNIFqUCsTxqK2gCQ?usp=sharing>

```
RegrasFinais.sort_values(by='lift', ascending =False)
```

	Antecedente	Consequente	suporte	confianca	lift
4	[Café]	[Pão, Manteiga]	0.3	1.0	2.5
0	[Café]	[Manteiga]	0.3	1.0	2.0
1	[Café]	[Pão]	0.3	1.0	2.0
5	[Café, Manteiga]	[Pão]	0.3	1.0	2.0
6	[Pão, Café]	[Manteiga]	0.3	1.0	2.0
2	[Manteiga]	[Pão]	0.4	0.8	1.6
3	[Pão]	[Manteiga]	0.4	0.8	1.6

3- Código implementado:

<https://colab.research.google.com/drive/1-uIA7RnM5S2ANprlwjKRjjf2D2lUSis?usp=sharing>

- Uma nova lista “itemsets” foi criada para armazenar os itemsets;
- Foi adicionado um append para o itemsets dentro do loop de transações para guardar cada itemset;
- Foi criado um dataframe para exibir os itemsets.

Itemsets gerados:

	Itemset 1	Itemset 2	Itemset 3
0	Café	Manteiga	None
1	Pão	Café	None
2	Pão	Manteiga	None
3	Pão	Café	Manteiga

4- Código implementado:

<https://colab.research.google.com/drive/1tidx8BdRrWKKQaI5fMZxMoBrWzNgOwqd?usp=sharing>

- Foi modificada a lógica de armazenamento dos valores == Sim para ≠Sim (Não)

	Antecedente	Consequente	suporte	confiança	lift
15	[Café, Cerveja]	[Manteiga]	0.4	0.800000	1.600000
27	[Pão, Café]	[Manteiga]	0.4	0.800000	1.600000
26	[Café, Manteiga]	[Pão]	0.4	0.800000	1.600000
25	[Pão]	[Café, Manteiga]	0.4	0.800000	1.600000
6	[Manteiga]	[Pão]	0.4	0.800000	1.600000
7	[Pão]	[Manteiga]	0.4	0.800000	1.600000
24	[Manteiga]	[Pão, Café]	0.4	0.800000	1.600000
19	[Café, Cerveja]	[Pão]	0.4	0.800000	1.600000
18	[Pão]	[Café, Cerveja]	0.4	0.800000	1.600000
14	[Manteiga]	[Café, Cerveja]	0.4	0.800000	1.600000
17	[Cerveja, Manteiga]	[Café]	0.4	1.000000	1.428571
28	[Pão, Manteiga]	[Café]	0.4	1.000000	1.428571
23	[Pão, Feijão]	[Café]	0.3	1.000000	1.428571
22	[Feijão, Manteiga]	[Café]	0.3	1.000000	1.428571
21	[Pão, Cerveja]	[Café]	0.4	1.000000	1.428571
29	[Pão, Cerveja, Manteiga]	[Café]	0.3	1.000000	1.428571

11	[Pão, Arroz]	[Café]	0.3	1.000000	1.428571
10	[Arroz, Manteiga]	[Café]	0.3	1.000000	1.428571
3	[Pão]	[Café]	0.5	1.000000	1.428571
2	[Manteiga]	[Café]	0.5	1.000000	1.428571
1	[Feijão]	[Arroz]	0.7	0.875000	1.093750
0	[Arroz]	[Feijão]	0.7	0.875000	1.093750
13	[Cerveja, Feijão]	[Arroz]	0.5	0.833333	1.041667
12	[Arroz, Cerveja]	[Feijão]	0.5	0.833333	1.041667
16	[Café, Manteiga]	[Cerveja]	0.4	0.800000	1.000000
20	[Pão, Café]	[Cerveja]	0.4	0.800000	1.000000
9	[Café, Feijão]	[Arroz]	0.4	0.800000	1.000000
8	[Café, Arroz]	[Feijão]	0.4	0.800000	1.000000
5	[Pão]	[Cerveja]	0.4	0.800000	1.000000
4	[Manteiga]	[Cerveja]	0.4	0.800000	1.000000

5- Código implementado:

<https://colab.research.google.com/drive/19vMI0VEmTHnI59CRLdJkk4GC-2Y3-Zlp?usp=sharing>

6- Resenha do artigo “A comprehensive review of visualization methods for association rule”:

O artigo "A comprehensive review of visualization methods for association rule" aborda diversas metodologias de visualização para regras de associação em data mining, focando em uma grande necessidade de apresentar resultados de mineração compreensíveis para usuários.

A obra se inicia dissertando sobre a evolução do ARM (Association Rule Mining), destacando como essa técnica identificou relações entre atributos em grandes databases transacionais, desde métodos tradicionais, como o Apriori, até outras abordagens mais contemporâneas.

O estudo categoriza e detalha uma cadeia dos métodos citados, agrupando-os em métodos “tradicionais” e “inovadores”. Dentre os métodos tradicionais, estão: Scatter Plot, Graph-Based, Matrix-Based, e Mosaic Plot. Essas técnicas servem para representar o suporte e a confiança das regras, com as visualizações Two-Key Plot e Double Decker Plot para ter interatividade. Os autores também apresentaram métodos de visualização mais atuais, como o diagrama Ishikawa (Fishbone), representação molecular, e mapas de metrô, os quais procuram facilitar o entendimento de regras mais complexas. Esses oferecem abordagens alternativas para exibir conjuntos extensos de regras, utilizando características como hierarquia e relações espaciais.

Uma seção importante é dedicada aos desafios da visualização em ARM, já citado anteriormente, incluindo a alta dimensionalidade e complexidade dos dados, que muitas vezes tornam as visualizações difíceis de interpretar para usuários comuns. A pesquisa é concluída sugerindo novas direções futuras para o desenvolvimento de métodos mais adaptáveis interativos, o que deve promover a transparência e interpretabilidade dos resultados em contextos de IA Explicável (XAI) e impedir situações de vieses humanos não explicados que podem gerar resultados catastróficos se aplicados em larga escala.

Em síntese, o artigo faz uma contribuição muito relevante ao consolidar e aplicar de forma didática as abordagens de visualização de regras de associação, concedendo uma base sólida para o avanço de técnicas que atendem melhor às necessidades de explicabilidade na análise de dados.